

รายงานสรุปผลการศึกษา

วิชา 2110291 เอกัตศึกษาทางวิศวกรรมคอมพิวเตอร์ 1

(Individual Study in Computer Engineering I)

เรื่อง

Clock drawing task in Parkinson disease patients

จัดทำโดย

นายพีรณัฐ ธีระวัฒนชัย

รหัสประจำตัวนิสิต 6231343821

เสนอ

อาจารย์ เอกพล ช่างสุวนิช

รายงานฉบับนี้เป็นส่วนหนึ่งของการศึกษารายวิชาเอกัตศึกษาทางวิศวกรรมคอมพิวเตอร์ 1

จุฬาลงกรณ์มหาวิทยาลัย

ภาคเรียนที่ 1 ปีการศึกษา 2563

คำนำ

รายงานฉบับนี้เป็นส่วนหนึ่งของการศึกษารายวิชาเอกศึกษาทางวิศวกรรมคอมพิวเตอร์ 1 (Individual Study in Computer Engineering I) จัดทำขึ้นเพื่อสรุปสิ่งที่ได้เรียนรู้จากวิชานี้ โดยได้ร่วมทำโปรเจกต์เรื่อง Machine Learning เกี่ยวกับการทำนายการเป็น Parkinson Disease จาก Features ต่างๆ ได้แก่ ข้อมูลทั่วไป Drawing Parameter และ Labels โดยในรายงานเล่มนี้ประกอบด้วยเนื้อหา ดังนี้

1. ความเป็นมาและวัตถุประสงค์
2. ขั้นตอนการทำงาน สิ่งที่ทำ
3. ผลลัพธ์ของงาน
4. อุปสรรคที่เกิดขึ้น วิธีแก้ปัญหา และสิ่งที่ได้รับจาก Individual Study นี้

ทั้งนี้ข้าพเจ้าหวังเป็นอย่างยิ่งว่ารายงานเล่มนี้จะเป็นประโยชน์ต่อผู้ที่ได้มาศึกษาเป็นอย่างดี และหากมีข้อผิดพลาดประการใดขออภัยมา ณ โอกาสนี้ด้วย

นายพีรณัฐ ชีระวัฒนชัย

ผู้จัดทำ

สารบัญ

รายละเอียด	หน้า
1. ความเป็นมาและวัตถุประสงค์	4
2. ขั้นตอนการทำงาน สิ่งที่ทำ	5
3. ผลลัพธ์ของงาน	6
4. อุปสรรคที่เกิดขึ้น วิธีแก้ปัญหา และสิ่งที่ได้รับจาก Individual Study นี้	15

1. ความเป็นมาและวัตถุประสงค์

- ความเป็นมา

ในปัจจุบันแม้เทคโนโลยีจะมีความก้าวหน้ามากขึ้น แต่การตรวจหาโรคบางชนิดก็ยังทำได้ยาก หรือ หากทำได้ต้องใช้เงินจำนวนมาก บุคลากรทางการแพทย์จึงคิดวิธีที่จะเก็บลักษณะเบื้องต้นของบุคคลคนหนึ่งที่มีนัยสำคัญต่อโรคนั้นทั้งที่เป็น และ ไม่เป็นโรค เพื่อนำมารวบรวม และ วิเคราะห์ได้ว่าบุคคลนั้นเป็นโรคชนิดนั้นหรือเปล่า ซึ่งวิธีหนึ่งในการเก็บข้อมูล คือ Clock drawing task ซึ่งเป็นการตรวจข้างเตียงที่ประสาทแพทย์ใช้ทดสอบผู้ป่วยที่มีความผิดปกติทางสมองชนิดต่างๆ เป็นการทดสอบทำได้ง่ายและให้ข้อมูลหลายแง่มุมที่ไว้ช่วยในการวินิจฉัยโรค เช่น โรคอัลไซเมอร์ โรคสมาธิบกพร่อง เป็นต้น โดยให้ผู้ป่วยวาดรูป "หน้าปัดนาฬิกาบอกเวลา สิบเอ็ดนาฬิกาสิบนาที" ลงบนกระดาษ ตัวอย่างความผิดปกติมีหลากหลาย เช่น การวาดนาฬิกาที่เข็มสั้นชี้ที่เลขสิบเอ็ดและเข็มยาวชี้ที่เลขสิบ (แทนที่จะเป็นเลขสอง) การวาดตัวเลขบนหน้าปัดนาฬิกาไม่ครบหรือเกินสิบสอง การวาดตัวเลขบนหน้าปัดนาฬิกาไปรวมอยู่ทางด้านขวาของนาฬิกา การวาดเข็มยาวกับเข็มสั้นยาวเท่ากัน วาดไม่เป็นนาฬิกา เป็นต้น โดยทางปฏิบัติในปัจจุบันแพทย์จะแปลผลโดยอาศัยผลลัพธ์ภาพวาดสุดท้ายเท่านั้น อย่างไรก็ตาม ข้อมูลระหว่างการวาด เช่น ความเร็ว หรือ ลำดับการวาด (temporal domain) ก็ดูจะมีความสำคัญ แม้ว่าทางการแพทย์จะยังไม่ได้นำมาใช้เท่าที่ควร เช่น บางคนเริ่มจากการลงเลข 12 6 3 ก่อนจะไปเขียนเลขตัวอื่นๆ ซึ่งบ่งว่ามีการวางแผนที่ดี

โดยในงานนี้ผมได้รับมอบหมายให้นำข้อมูลที่เก็บมาจากตัวอย่าง 196 คน สร้าง Machine Learning เพื่อให้วิเคราะห์ว่า Clock drawing task สามารถใช้บ่งบอกการเป็นหรือไม่เป็นโรคพาร์คินสันได้หรือไม่ และ เป้าหมายหลัก คือ การใช้ข้อมูลต่างๆ เพื่อให้การทำนายเกิดความแม่นยำมากที่สุด โดยข้อมูลที่กำหนดมาให้แบ่งออกเป็น

1. ข้อมูลทั่วไป ได้แก่ เพศ อายุ คะแนน TMSE (Thai mini mental status examination) การศึกษา วันที่เก็บข้อมูล ระยะเวลาที่เป็น และ มือข้างถนัด
2. Drawing Parameter ซึ่งเก็บมาอยู่ในรูป Array
 - 2.1 t เก็บเวลาที่แต่ละจุดที่ถูกวาด
 - 2.2 x เก็บพิกัด X ของแต่ละจุด
 - 2.3 y เก็บพิกัด Y ของแต่ละจุด
 - 2.4 p เก็บความหนักของการวาดแต่ละจุด
 - 2.5 pt เก็บลักษณะของแต่ละจุด (1 = เริ่ม , 2 = ลาก , 3 = ยก)
3. Labels ระบุว่าแต่ละคนเป็นโรคพาร์คินสันหรือไม่ และ วาดรูปนาฬิกาปกติหรือไม่

- วัตถุประสงค์

1. เพื่อทำนายการเป็น Parkinson Disease จาก Features ต่างๆ ได้แก่ ข้อมูลทั่วไป (Age , Date , Ed , Gender , Duration , Side , TMSE) Drawing Parameter และ Labels ให้มีความแม่นยำมากที่สุด
2. เพื่อทดสอบว่า Clock drawing task สามารถใช้บ่งบอกการเป็นหรือไม่เป็นโรคพาร์กินสันได้หรือไม่
3. เพื่อศึกษาการทำ Machine Learning ใน Google Colaboratory
4. เพื่อศึกษาการเขียนโปรแกรมภาษา Python ใน Google Colaboratory

2. ขั้นตอนการทำงาน สิ่งที่ทำ

- ขั้นตอนการทำงาน

1. ศึกษาการทำ Machine Learning จาก “Applied Machine Learning in Python by University of Michigan” ใน Coursera เพื่อให้ทราบถึงพื้นฐานการทำ Machine Learning เช่น การแบ่งข้อมูล การทดสอบข้อมูลแบบต่างๆ และการนำข้อมูลมาวิเคราะห์ เป็นต้น
2. วางแผน หรือ แนวทางในการทำงาน
3. เริ่มทำงานใน Google Colaboratory จนสำเร็จ
4. ตรวจสอบความถูกต้องของงาน
5. ทำรูปเล่มสรุปการทำงาน

- สิ่งที่ทำ

1. Google Colaboratory : ภายในเป็นการเขียนโปรแกรมด้วย Python เพื่อตอบสนองวัตถุประสงค์ที่จะทำนายการเป็น Parkinson Disease จาก Features ต่างๆ ให้มีความแม่นยำมากที่สุด และ ทดสอบว่า Clock drawing task สามารถใช้บ่งบอกการเป็นหรือไม่เป็นโรคพาร์กินสันได้หรือไม่
2. รูปเล่มสรุปการทำงาน : ภายในเป็นการสรุปผลงานที่ทำ อุปสรรคที่เกิดขึ้นระหว่างการทำงาน แนวทางแก้ไข และ สิ่งที่ได้จากการศึกษาครั้งนี้

3. ผลลัพธ์ของงาน (Reading_mat_PD.ipynb)

0. Import สิ่งที่ต้องใช้

1. Making Dataframe โดยใช้ pandas และ ปรับเปลี่ยน และ เพิ่มข้อมูลต่างๆ เข้าไปในตาราง

1.1 clock_image : สร้างภาพวาดนาฬิกาจากพิกัดจุด และ ลักษณะของเส้นต่างๆ โดยจะใช้ ImageDraw ในจุดที่ pt!=1

1.2 t : เปลี่ยนเป็นใช้ระยะเวลาสุดท้ายที่ใช้วาด

1.3 ed , gender , side: เปลี่ยนเป็นใช้เฉพาะตัวเลขด้านหน้าแทน

1.4 dates , month : เพิ่มข้อมูลวันและเดือนที่จัดเก็บข้อมูลลงไปในตาราง

1.5 pressure_mean , pressure_std : เพิ่มข้อมูลค่าเฉลี่ย และ ส่วนเบี่ยงเบนมาตรฐานของแรงกดปากกาลงไปในตาราง

1.6 TMSE_pass : เพิ่มข้อมูลว่าแต่ละคนผ่านเกณฑ์ทดสอบตามอายุหรือไม่ (0 = failed / 1 = pass)

1.7 นำข้อมูล x , y , pt , duration ออกจากตาราง

1.8 นำข้อมูลของคนทีกรอกอายุ และ TMSE ไม่ครบถ้วน ออกไปทั้งหมด

2. Classification

2.1 Use all features :
'TMSE','clock_drawing','t','ed','gender','side','age','dates','month','pressure_mean',
'pressure_std','TMSE_pass' (Overfit)

Accuracy of KNeighborsClassifier : 0.8182

F1 score of KNeighborsClassifier: 0.8710

Accuracy of Logistic Regression on training set: 0.8182

Accuracy of Logistic Regression on test set: 0.7727

F1 score of Logistic Regression: 0.8276

Accuracy of Linear SVC classifier on training set: 0.8106

Accuracy of Linear SVC classifier on test set: 0.7500

F1 score of Linear SVC classifier: 0.8136

Accuracy of RBF-kernel SVC on training set: 0.8939

Accuracy of RBF-kernel SVC on test set: 0.7727

F1 score of RBF-kernel SVC: 0.8333

Accuracy of Cross Validation on training set: [0.77777778 0.66666667 0.73076923 0.61538462 0.80769231]

Mean of Cross Validation on training set: 0.7197

Accuracy of Cross Validation on test set: [0.77777778 0.77777778 0.66666667 0.77777778 0.625]

Mean of Cross Validation on test set: 0.7250

F1 score of DT classifier: 0.8710

Accuracy of DT classifier on training set: 1.00
 Accuracy of DT classifier on test set: 0.84
 F1 score of DT classifier: 0.8852

Logistic regression classifier

[[10 3]

[7 24]]

	precision	recall	f1-score	support
0	0.59	0.77	0.67	13
1	0.89	0.77	0.83	31
accuracy			0.77	44
macro avg	0.74	0.77	0.75	44
weighted avg	0.80	0.77	0.78	44

Kernelized Support Vector Machines

[[9 4]

[6 25]]

	precision	recall	f1-score	support
0	0.60	0.69	0.64	13
1	0.86	0.81	0.83	31
accuracy			0.77	44
macro avg	0.73	0.75	0.74	44
weighted avg	0.78	0.77	0.78	44

Accuracy of GaussianNB classifier on training set: 0.7879
 Accuracy of GaussianNB classifier on test set: 0.8182
 F1 score of GaussianNB classifier: 0.8667

Accuracy of RF classifier on training set: 1.0000
 Accuracy of RF classifier on test set: 0.7727
 F1 score of RF classifier: 0.8276

Accuracy of GBDT classifier on training set: 1.0000
 Accuracy of GBDT classifier on test set: 0.8636
 F1 score of GBDT classifier: 0.8276

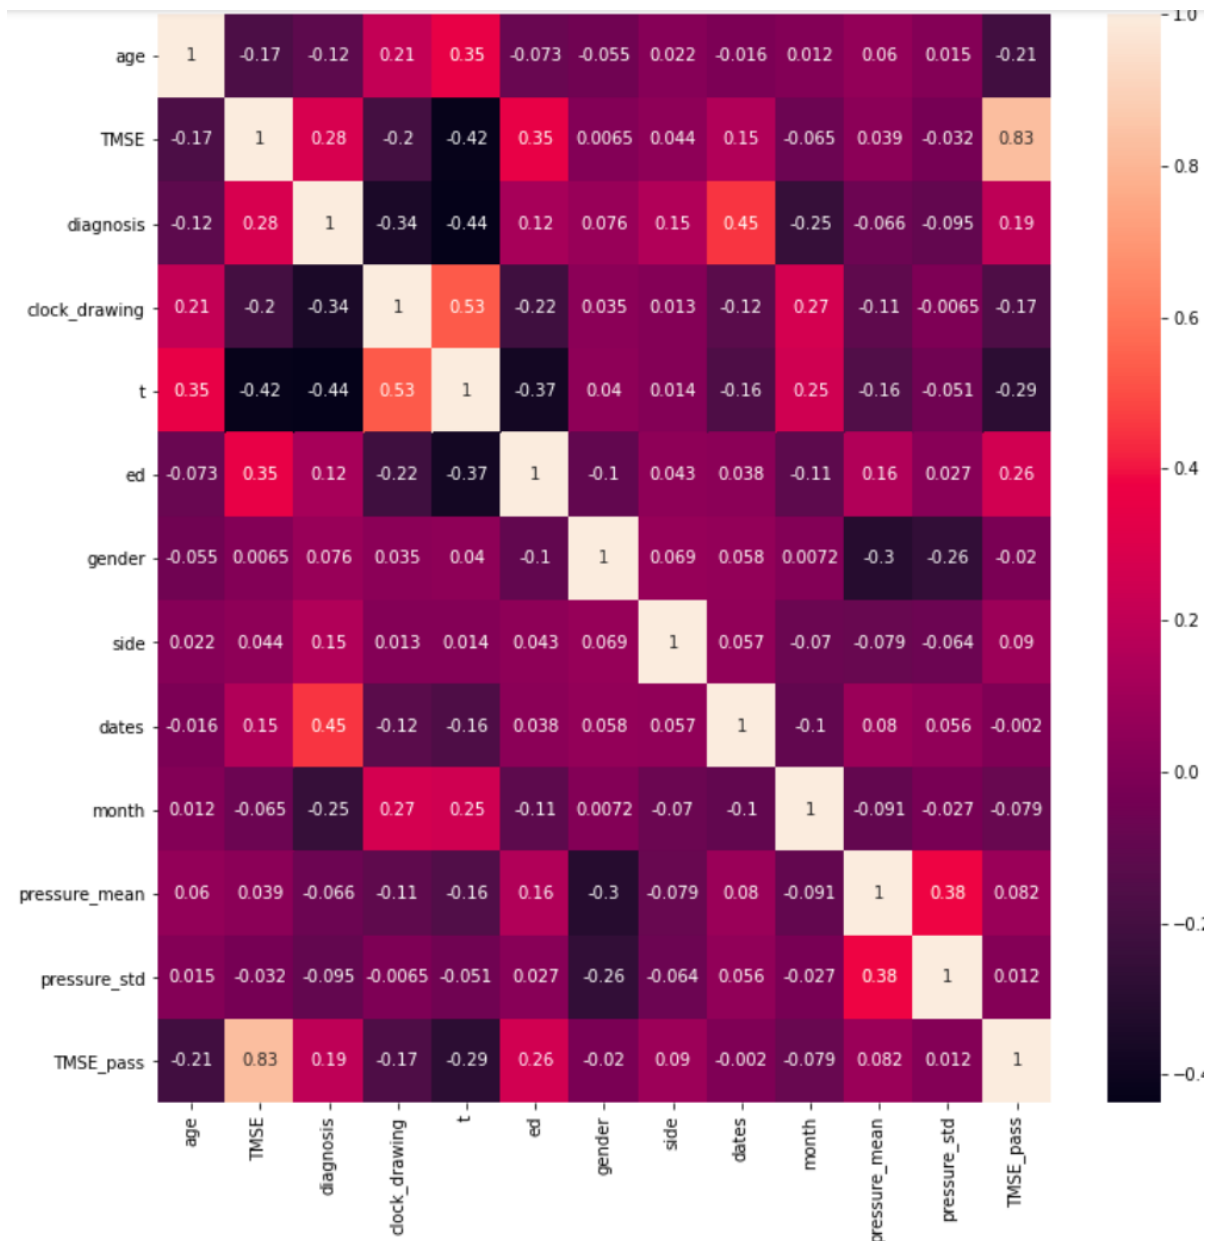
Accuracy of NN classifier on training set: 0.7955
 Accuracy of NN classifier on test set: 0.7500
 F1 score of NN classifier: 0.8276

Accuracy Score for KFold with SVC: 0.6980392156862745 +- 0.09069672553569494
 F1 Score for KFold with SVC: 0.7310853962970667 +- 0.09508771613460701

Accuracy Score for KFold with lr: 0.7205882352941176 +- 0.11357560929561418
 F1 Score for KFold with lr: 0.7645459080561383 +- 0.09700373904804684

Using KFold because this model has little amount of data (176 data). So, we should use KFold to divide data into test and train 10 times differently.

2.2 Using some important features : Using Heatmap to determine what features should we use



2.2.1 'clock_drawing', 't', 'dates' : most top 3 relation between 'diagnosis' and features (best for logistic regression)

Accuracy of Logistic Regression on training set: 0.7500
 Accuracy of Logistic Regression on test set: 0.8636
 F1 score of Logistic Regression: 0.8966

Accuracy of RBF-kernel SVC on training set: 0.7424
 Accuracy of RBF-kernel SVC on test set: 0.8864
 F1 score of RBF-kernel SVC: 0.9123


```

Logistic regression classifier
[[12  1]
 [ 5 26]]

```

	precision	recall	f1-score	support
0	0.71	0.92	0.80	13
1	0.96	0.84	0.90	31
accuracy			0.86	44
macro avg	0.83	0.88	0.85	44
weighted avg	0.89	0.86	0.87	44

```

Kernelized Support Vector Machines
[[13  0]
 [ 5 26]]

```

	precision	recall	f1-score	support
0	0.72	1.00	0.84	13
1	1.00	0.84	0.91	31
accuracy			0.89	44
macro avg	0.86	0.92	0.88	44
weighted avg	0.92	0.89	0.89	44

Accuracy Score of KFold with SVC: 0.6836601307189542 +- 0.09976477096776487

F1 Score of KFold with SVC: 0.736281354038791 +- 0.08702159707438034

Different between accuracy score with SVC : -0.0144

Different between F1 score with SVC : 0.0052

Accuracy Score of KFold with lr: 0.7333333333333334 +- 0.11342458878188266

F1 Score of KFold with lr: 0.7674331223743871 +- 0.12513474798987131

Different between accuracy score with lr: 0.0127

Different between F1 score with lr: 0.0029

2.2.2 'TMSE','t','dates','month','clock_drawing' : most top 5 relation between 'diagnosis' and features (best for SVC) (**best features**)

Accuracy of Logistic Regression on training set: 0.7803

Accuracy of Logistic Regression on test set: 0.7727

F1 score of Logistic Regression: 0.8333

Accuracy of RBF-kernel SVC on training set: 0.8182

Accuracy of RBF-kernel SVC on test set: 0.7727

F1 score of RBF-kernel SVC: 0.8387

```

Logistic regression classifier
[[ 9  4]
 [ 6 25]]

```

	precision	recall	f1-score	support
0	0.60	0.69	0.64	13
1	0.86	0.81	0.83	31
accuracy			0.77	44
macro avg	0.73	0.75	0.74	44
weighted avg	0.78	0.77	0.78	44

```

Kernelized Support Vector Machines
[[ 8  5]
 [ 5 26]]

```

	precision	recall	f1-score	support
0	0.62	0.62	0.62	13
1	0.84	0.84	0.84	31
accuracy			0.77	44
macro avg	0.73	0.73	0.73	44
weighted avg	0.77	0.77	0.77	44

Accuracy Score of KFold with SVC: 0.7839869281045752 +- 0.08233024378575299
 F1 Score of KFold with SVC: 0.827405808614875 +- 0.05471399697551324
 Different between accuracy score with SVC : 0.0859
 Different between F1 score with SVC : 0.0963

Accuracy Score of KFold with lr: 0.7611111111111111 +- 0.11269962140518698
 F1 Score of KFold with lr: 0.7890503696994198 +- 0.12059282565147927
 Different between accuracy score with lr: 0.0405
 Different between F1 score with lr: 0.0245

2.2.3 'dates','TMSE','TMSE_pass' : most top 3 positive relation between 'diagnosis' and features (balance)

```

..
Accuracy of Logistic Regression on training set: 0.7879
Accuracy of Logistic Regression on test set: 0.8182
F1 score of Logistic Regression: 0.8621

Accuracy of RBF-kernel SVC on training set: 0.7576
Accuracy of RBF-kernel SVC on test set: 0.8182
F1 score of RBF-kernel SVC: 0.8621

```

```

Logistic regression classifier
[[11  2]
 [ 6 25]]
      precision    recall  f1-score   support

      0       0.65       0.85       0.73        13
      1       0.93       0.81       0.86        31

   accuracy               0.82        44
  macro avg       0.79       0.83       0.80        44
 weighted avg       0.84       0.82       0.82        44

Kernelized Support Vector Machines
[[11  2]
 [ 6 25]]
      precision    recall  f1-score   support

      0       0.65       0.85       0.73        13
      1       0.93       0.81       0.86        31

   accuracy               0.82        44
  macro avg       0.79       0.83       0.80        44
 weighted avg       0.84       0.82       0.82        44

```

Accuracy Score of KFold with SVC: 0.7163398692810456 +- 0.11272188829966062
 F1 Score of KFold with SVC: 0.7657835913805762 +- 0.0871097812434922
 Different between accuracy score with SVC : 0.0183
 Different between F1 score with SVC : 0.0347

Accuracy Score of KFold with lr: 0.7663398692810457 +- 0.07296076411393804
 F1 Score of KFold with lr: 0.8072525584673922 +- 0.061933738520241415
 Different between accuracy score with lr: 0.0458
 Different between F1 score with lr: 0.0427

2.2.4 'TMSE','TMSE_pass','side' : most top 3 positive relation between 'diagnosis' and features without date and month

Accuracy of Logistic Regression on training set: 0.6439
 Accuracy of Logistic Regression on test set: 0.7273
 F1 score of Logistic Regression: 0.8286

Accuracy of RBF-kernel SVC on training set: 0.6515
 Accuracy of RBF-kernel SVC on test set: 0.7045
 F1 score of RBF-kernel SVC: 0.8169

```

Logistic regression classifier
[[ 3 10]
 [ 2 29]]

```

	precision	recall	f1-score	support
0	0.60	0.23	0.33	13
1	0.74	0.94	0.83	31
accuracy			0.73	44
macro avg	0.67	0.58	0.58	44
weighted avg	0.70	0.73	0.68	44

```

Kernelized Support Vector Machines
[[ 2 11]
 [ 2 29]]

```

	precision	recall	f1-score	support
0	0.50	0.15	0.24	13
1	0.72	0.94	0.82	31
accuracy			0.70	44
macro avg	0.61	0.54	0.53	44
weighted avg	0.66	0.70	0.65	44

Accuracy Score of KFold with SVC: 0.6088235294117647 +- 0.1318824850982451
 F1 Score of KFold with SVC: 0.7483989221959189 +- 0.10354114875332512
 Different between accuracy score with SVC : -0.0892
 Different between F1 score with SVC : 0.0173

Accuracy Score of KFold with lr: 0.6578431372549021 +- 0.10022668569687757
 F1 Score of KFold with lr: 0.7441033273569425 +- 0.09436600107734197
 Different between accuracy score with lr: -0.0627
 Different between F1 score with lr: -0.0204

2.2.5 Making Least accuracy : Using 'pressure_mean','pressure_std','gender'

(most top 3 least relation between 'diagnosis' and features)

Accuracy of Logistic Regression on training set: 0.5758
 Accuracy of Logistic Regression on test set: 0.6591
 F1 score of Logistic Regression: 0.7826

Accuracy of RBF-kernel SVC on training set: 0.6818
 Accuracy of RBF-kernel SVC on test set: 0.6818
 F1 score of RBF-kernel SVC: 0.7941

```

Logistic regression classifier
[[ 2 11]
 [ 4 27]]

```

	precision	recall	f1-score	support
0	0.33	0.15	0.21	13
1	0.71	0.87	0.78	31
accuracy			0.66	44
macro avg	0.52	0.51	0.50	44
weighted avg	0.60	0.66	0.61	44

```

Kernelized Support Vector Machines
[[ 3 10]
 [ 4 27]]

```

	precision	recall	f1-score	support
0	0.43	0.23	0.30	13
1	0.73	0.87	0.79	31
accuracy			0.68	44
macro avg	0.58	0.55	0.55	44
weighted avg	0.64	0.68	0.65	44


Accuracy Score of KFold with SVC: 0.6101307189542483 +- 0.11089993388243076
 F1 Score of KFold with SVC: 0.752125592448173 +- 0.08354495697482286
 Different between accuracy score with SVC : -0.0879
 Different between F1 score with SVC : 0.0210

Accuracy Score of KFold with lr: 0.607843137254902 +- 0.09232821412909731
 F1 Score of KFold with lr: 0.7517903816613494 +- 0.0750530672489475
 Different between accuracy score with lr: -0.1127
 Different between F1 score with lr: -0.0128


2.3 Use 'clock_image' by deep learning

2.3.1 Model1 : Reference :

https://www.youtube.com/watch?v=CM92plh1Unw&ab_channel=IBMDeveloper
 (Cannot used)

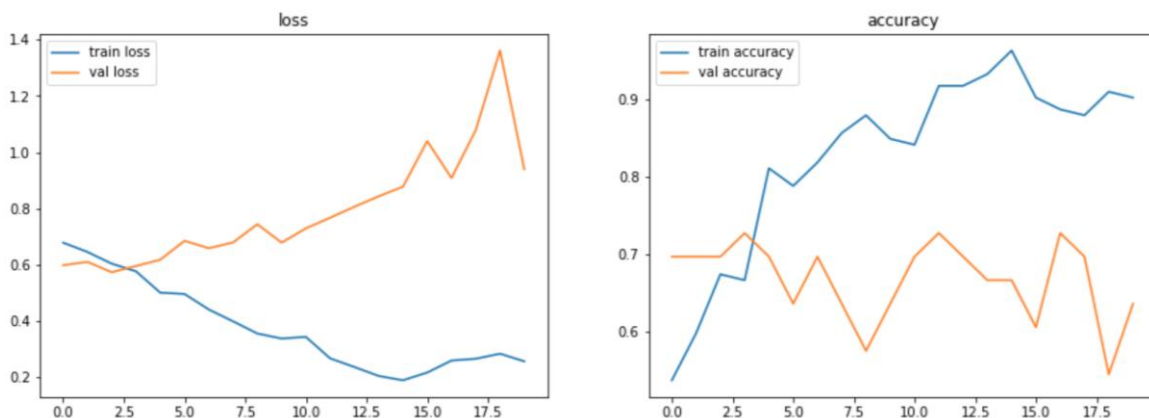


2.3.2 Model 2 : Change compile loss to 'binary_crossentropy' and output activation to 'sigmoid' (Overfit because train loss and val loss are very far)




Accuracy Score : 0.7272727272727273

2.3.3 Dropout Model : <https://www.bualabs.com/archives/1533/what-is-dropout-benefits-dropout-reduce-overfit-deep-learning-training-model-deep-neural-network-regularization-ep-2/> (Reduce Overfit)



Accuracy Score : 0.7272727272727273

2.3.4 Change dropout value = 0.75 (least overfit) (**best model**)



4. อุปสรรคที่เกิดขึ้น วิธีแก้ปัญหา และสิ่งที่ได้รับจาก Individual Study นี้

- อุปสรรคที่เกิดขึ้น และ วิธีแก้ปัญหา

1. อุปสรรค : ไม่ทราบโครงสร้างของโค้ดบางส่วนที่อยู่นอกเหนือจากการไปศึกษามา และ จำเป็นต้องใช้ในงานนี้

วิธีแก้ : ไปค้นหาเพิ่มเติมในอินเทอร์เน็ต หรือ ถามเพื่อนที่ทำงานด้วยกัน

2. อุปสรรค : ข้อมูลบางส่วนที่กำหนดมาให้ไม่สมบูรณ์ตามที่โจทย์บอกไว้ ได้แก่ อายุ และ คะแนน TMSE

วิธีแก้ : ตัดข้อมูลทั้งหมดของคนนั้นออกไปหากมีสักช่องที่กรอกข้อมูลมาไม่สมบูรณ์

3. อุปสรรค : ไม่รู้แนวทางในการวาดรูปนาฬิกาจากพิกัดจุดต่างๆ ที่กำหนดมาให้

วิธีแก้ : ไปค้นหาเพิ่มเติมในอินเทอร์เน็ต หรือ ถามเพื่อนที่ทำงานด้วยกัน และ อาจารย์ที่ปรึกษา

- สิ่งที่ได้รับจาก Individual Study นี้

1. ได้สรุปผลว่า Clock drawing task สามารถใช้บ่งบอกการเป็นหรือไม่เป็นโรคพาร์กินสันได้เป็นส่วนใหญ่แต่ไม่ใช่ทั้งหมด (Model ที่เหมาะสมที่สุดบอกได้ประมาณ 72%) และ สามารถทำนายการเป็น Parkinson Disease จาก Features ต่างๆ ได้โดยมีความแม่นยำที่สูง (มากที่สุดประมาณ 78%)

2. ได้เรียนรู้เกี่ยวกับการทำ Machine Learning ในรูปแบบต่างๆ ทั้ง Supervised และ Unsupervised Learning

3. ได้นำ Supervised Learning และ Deep Learning มาใช้ทำงานวิเคราะห์การเป็นโรคพาร์กินสันจากข้อมูลต่างๆ ที่มีอยู่

4. ได้ทบทวนการเขียนโปรแกรมด้วย Python และ การใช้ Google Colaboratory

Reference

https://www.youtube.com/watch?v=CM92plh1Unw&ab_channel=IBMDeveloper

<https://www.bualabs.com/archives/1533/what-is-dropout-benefits-dropout-reduce-overfit-deep-learning-training-model-deep-neural-network-regularization-ep-2/>
